

Estudo sobre Neural networks for geospatial data (NN-GLS)

Estimação de Parâmetros e Modelagem Espacial com INLA

Pedro Dresseno John e Yuri Dessimon

Co-autroa: Profa. Dra. Márcia H. Barbian
Departamento de Estatística
Instituto de Matemática e Estatística
Universidade Federal do Rio Grande do Sul (UFRGS)

2 de setembro de 2026

Séries Temporais como Processo Estocástico

Definição


Uma série temporal é uma realização de um processo estocástico, isto é, uma coleção de variáveis aleatórias indexadas no tempo:

$$\{X_t, t \in T\},$$

em que cada X_t representa o valor observado da variável no instante t .

Processo estocástico

- O conjunto $\{X_t\}$ é aleatório;
- Uma série observada é apenas uma realização;
- O objetivo é modelar a dependência entre os instantes de tempo.




Do Processo Temporal à um Processo Espacial

Mesma ideia, índice diferente

Respostas $y(\mathbf{s})$ observadas como versão ruidosa de um processo gaussiano $Z(\cdot) = \{Z(\mathbf{s}) : \mathbf{s} \in \mathbb{R}^2\}$.


Série temporal

$$\{X(t) : t \in \mathbb{R}\}$$



Processo espacial

$$\{Y(\mathbf{s}) : \mathbf{s} \in \mathbb{R}^2\}$$



Pressupostos do Processo Gaussiano

Hipótese fundamental

Assume-se que a variável espacial é uma realização de um processo gaussiano $Z(s)$, de modo que qualquer conjunto finito de observações possui distribuição Normal multivariada.

Pressupostos

- Média: $E[\mathbf{Y}] = \mathbf{X}\beta$;
- Matriz de covariância: Σ ;
- Dependência espacial modelada por $C(\mathbf{h})$;
- Covariância depende do vetor de separação $\mathbf{h}$ (estacionariedade) e/ou da distância $\|\mathbf{h}\|$ (isotropia);
- O item anterior depende do tipo de estacionariedade assumida.

$$\mathbf{Y} = \begin{bmatrix} Y(\mathbf{s}_1) \\ Y(\mathbf{s}_2) \\ \vdots \\ Y(\mathbf{s}_n) \end{bmatrix} \sim \mathcal{N}(\mathbf{X}\beta, \Sigma)$$

Modelo Geoestatístico

$$Y(\mathbf{s}) \sim \mathcal{GP}(\mathbf{X}\boldsymbol{\beta}, C(h; \boldsymbol{\theta}) + \tau^2 \mathbb{I}(h = 0))$$

Usando o modelo geoestatístico:

$$y(\mathbf{s}) = \mu(\mathbf{s}) + w(\mathbf{s}) + \epsilon(\mathbf{s})$$

onde:

- $\mu(\mathbf{s}) = \mathbf{X}\boldsymbol{\beta}$ é a tendência do processo em grande escala.
- $w(\mathbf{s}) \sim \mathcal{GP}(0, C(\cdot; \boldsymbol{\theta}))$ é um Processo Gaussiano de média zero que captura a dependência espacial de pequena escala.
- $\epsilon(\mathbf{s}) \stackrel{i.i.d.}{\sim} \mathcal{N}(0, \tau^2)$ efeito pepita.

Função de Covariância de Matérn

$$C(h; \sigma^2, \kappa, \nu) = \frac{\sigma^2}{2^{\nu-1}\Gamma(\nu)} (\kappa h)^\nu K_\nu(\kappa h), \text{ onde } h = \|\mathbf{s}_i - \mathbf{s}_j\|.$$

Contextualização e Motivação

- **Contexto atual:**

- *Modelos Geoestatísticos*: Modelam adequadamente a autocorrelação, porém a fórmula da tendências precisa ser especificada com antecedência;
- *Redes Neurais Artificiais*: Capturam não linearidades e interações complexas dos preditores, mas violam a suposição de independência (*i.i.d.*) dos erros.

- **Trabalho atual e o que fizemos de novo:**

- Aplicar uma rede específica para dados espaciais;
- Modificação no método de estimação de parâmetros.

Proposta do NN-GLS

$$\begin{aligned} y(\mathbf{s}) &= f(X(\mathbf{s})) + w(\mathbf{s}) + \epsilon(\mathbf{s}), \\ w(\cdot) &\sim GP(0, \Sigma(\cdot, \cdot)), \\ \epsilon(\cdot) &\sim GP(0, \tau^2 \mathbf{I}). \end{aligned}$$

- Estimar $f(X(\mathbf{s}))$ usando uma rede neural que leva em conta a dependência espacial;
- Utilizar o Mínimos Quadrados Generalizados (MQG/GLS).

Mínimos Quadrados Generalizados

$$\mathcal{L}_n(f) = \frac{1}{n}(\mathbf{Y} - f(\mathbf{X}))^\top \Sigma^{-1}(\mathbf{Y} - f(\mathbf{X})).$$

Mínimos Quadrados Ordinários

$$\mathcal{L}_n(f) = \frac{1}{n}(\mathbf{Y} - f(\mathbf{X}))^\top (\mathbf{Y} - f(\mathbf{X})).$$

Desafio da proposta

- GLS não é compatível com a técnica de mini-batching por não possuir aditividade como OLS;
- Back-propagation envolve a inversão de uma matriz $n \times n$ que requer $\mathcal{O}(n^2)$ espaço de memória e $\mathcal{O}(n^3)$ tempo de cada interação;


Como o artigo contornou esses problemas?

Como o artigo contornou esse problema?

Ideia central

- Utilizar o **Nearest Neighbor Gaussian Process (NNGP)** que reduz a complexidade computacional ao calcularmos Σ apenas com os vizinhos mais próximos;
- Transformar o problema de GLS em um problema equivalente de OLS.

GP Completo vs NNGP



Ideia central

Uma perda GLS pode ser vista como uma perda OLS para a resposta decorrelacionada $\mathbf{Y}^* = \mathbf{Q}^{\frac{1}{2}} \mathbf{Y}$, em que $\mathbf{Q}^{\frac{1}{2}}$ é o fator de Cholesky de $\mathbf{Q} = \mathbf{Q}^{\frac{\top}{2}} \mathbf{Q}^{\frac{1}{2}}$.

Para trabalharmos com GLS o artigo propõe a transformação acima que decorrelaciona as respostas. Logo a rede vira:

- ❶ Decorrelação espacial (com de parâmetros iniciais da func de covariância);
- ❷ Treinamento de MLP;
- ❸ Camada de output da MLP é uma convolução;
- ❹ Cálculo dos resíduos;
- ❺ Depois de fazer backpropagation um número M de vezes, estimar os parâmetros novamente.

Estimação dos Parâmetros Espaciais

Objetivo

Estimar os parâmetros da matriz de covariância

$$\theta = (\sigma^2, \phi, \tau^2),$$

utilizando os resíduos produzidos pela rede neural.

$$\mathbf{w} = \mathbf{y} - \hat{\mathbf{y}}$$

- A MLP estima apenas a média não linear $f(\mathbf{x})$;
- A dependência espacial permanece nos resíduos $\mathbf{w}$;
- A cada época, os parâmetros espaciais são reestimados e uma nova matriz $\Sigma(\theta)$ é construída.

MLP $\rightarrow$ Resíduos $\rightarrow$ Estimação de $\theta \rightarrow$ Nova Σ

Estimação por BRISC

Ideia principal

O BRISC estima $\theta = (\sigma^2, \phi, \tau^2)$ por Máxima Verossimilhança utilizando a aproximação do NNGP.

A log-verossimilhança aproximada é dada por

$$\ell(\theta) = -\frac{1}{2} \sum_{i=1}^n \left[\log(F_i) + \frac{(w_i - \mathbf{B}_i \mathbf{w}_{N_i})^2}{F_i} \right].$$

- Constrói vizinhos mais próximos para cada observação;
- Evita inverter a matriz $\Sigma_{n \times n}$ completa;
- Complexidade aproximadamente linear em n ;
- Retorna estimativas MLE de σ^2 , ϕ e τ^2 .

Estimação Bayesiana por INLA

Ideia principal

O INLA obtém a distribuição posterior dos parâmetros espaciais sem utilizar MCMC.

Modelo hierárquico:

$$\mathbf{w} \mid \theta \sim \mathcal{N}(0, \Sigma(\theta))$$

$$\pi(\theta \mid \mathbf{w}) \propto \pi(\mathbf{w} \mid \theta) \pi(\theta)$$

O INLA aproxima numericamente as distribuições posteriores de

$$\sigma^2, \quad \phi, \quad \tau^2.$$

- Inferência Bayesiana rápida por aproximações de Laplace;
- Fornece média, moda, desvio padrão e intervalos de credibilidade;
- Permite quantificar a incerteza dos parâmetros espaciais.


Estudo de Simulação

- Foi usada a função `grf()` do pacote `geoR`;
- Função de covariância Matérn ($\nu = 1$);
- **Geração dos Dados:**
- coordenadas $\sim \text{runif}(0,10)$
- $\mathbf{X} \sim \text{unif}(0,1)$

$$\mu(s) = \frac{1}{6}(10 \sin(\pi x_1(s)x_2(s)) + 20(x_3(s) - 0.5)^2 + 10x_4(s) + 5x_5(s))$$

- **Cenários Amostrais - INLA:** $n = 2000$
 - **Variância Espacial (σ^2):** $\{0.5, 1.0, 5.0, 10.0, 20.0\}$
 - **Alcance Espacial $\cdot \sqrt{2}$:** $\{0.5, 1, 3, 6, 12\}$
 - **Pepita:** $\tau^2 = 0.1 \cdot \sigma^2$


Resultados Comparativos



σ_{real}^2	ϕ_{real}	EQM Bayes	EQM Freq	Média Δ	DP Δ	Mín Δ	Máx Δ	% Bayes Melhor
0.5	$\frac{0.5}{\sqrt{2}}$	0.577	0.604	0.0274	0.0184	-0.0036	0.0786	98
0.5	$\frac{3}{\sqrt{2}}$	0.492	0.521	0.0294	0.0462	-0.0102	0.2503	84
0.5	$\frac{12}{\sqrt{2}}$	0.465	0.731	0.2655	0.3017	0.0068	1.5456	100
1.0	$\frac{0.5}{\sqrt{2}}$	0.760	0.777	0.0169	0.0108	-0.0021	0.0482	98
1.0	$\frac{3}{\sqrt{2}}$	0.514	0.530	0.0160	0.0143	-0.0096	0.0563	94
1.0	$\frac{12}{\sqrt{2}}$	0.519	0.607	0.0876	0.1447	-0.0068	0.6935	98
5.0	$\frac{0.5}{\sqrt{2}}$	2.230	2.230	0.0011	0.0087	-0.0196	0.0319	54
5.0	$\frac{3}{\sqrt{2}}$	1.190	1.180	-0.0129	0.0161	-0.0620	0.0171	22
5.0	$\frac{12}{\sqrt{2}}$	0.963	0.976	0.0126	0.0396	-0.0257	0.2303	60
10.0	$\frac{0.5}{\sqrt{2}}$	3.840	3.830	-0.0094	0.0227	-0.0670	0.0373	40
10.0	$\frac{3}{\sqrt{2}}$	2.010	2.000	-0.0169	0.0212	-0.0805	0.0241	20
10.0	$\frac{12}{\sqrt{2}}$	1.660	1.640	-0.0196	0.0219	-0.0635	0.0159	18
20.0	$\frac{0.5}{\sqrt{2}}$	7.280	7.260	-0.0213	0.0565	-0.1245	0.1019	36
20.0	$\frac{3}{\sqrt{2}}$	3.600	3.580	-0.0294	0.0346	-0.1337	0.0516	20
20.0	$\frac{12}{\sqrt{2}}$	2.860	2.840	-0.0215	0.0393	-0.1277	0.0445	26

Resultados Comparativos

- Clara relação entre a porcentagem de vitórias da estimação Bayesiana e a dependência espacial;
- Leve relação com o parâmetro ϕ ;
- As vitórias do INLA são mais expressivas.




Aplicação em dados reais










- Encontramos a base de dados "African open soil data" feita pela empresa sem fins-lucrativos iSDA (Innovative Solutions for Decision Agricultured);
- Essa empresa cria modelos baseado em AI com o intuito impulsionar a renda de fazendeiros de micro-escala;
- Ideia da nossa aplicação é modelar o nível de pH em uma região;
- Embora já tenha sido aplicado redes neurais nesses dados, pelo que sabemos, nunca foi aplicado NN-GLS.

Dados

- Nos delimitamos as regiões: Mwanza, Geita, Simiyu, Mara e Shinyanga;
- Variável resposta: pH;
- Covariáveis: Carbono, Nitrogênio, Alumínio, Cálcio, Cobre, Ferro, Manganês, Magnésio, Potássio, Latitude e Longitude.






Histogramas



Histogramas

Tabela: Comparação de Desempenho e Parâmetros dos Métodos de Estimação

Método	Tempo	σ^2	ϕ	τ^2	EQM
INLA	1 min 16 s	0.01849	0.111	3.82719	0.07797
BRISC	42 s	0.05974	0.104	1.37450	0.10522
Vero. Completa	22 min 2 s	0.05485	0.13075	1.57582	0.11426






Figura: Krigagem Ordinária com do método Bayesiano




Figura: Diagnóstico dos resíduos do modelo NN-GLS com INLA

Conclusões e Trabalhos Futuros

Conclusões:

- Eficiência de cada método está diretamente relacionada à intensidade da dependência espacial presente nos dados;
- INLA foi mais vantajoso em cenários com dependência espacial baixa;
- Escolha do método deve levar em conta a natureza dos parâmetros.

Trabalhos Futuros:

- Simulações com anisotropia e dupla tendência;
- Testar outras prioris;
- Modificar de outra forma o conjunto de condicionamento.

Agradecimentos

Obrigado pela atenção!

Yuri Dessimon

yuri.dessimon@ufrgs.br

Instituto de Matemática e Estatística (IME)
Universidade Federal do Rio Grande do Sul (UFRGS)